

研镜：面向科研的透明学术调研智能体工作台

第八届中国研究生人工智能创新大赛·开放赛题一（生成式大语言模型与智能体）

版本：0.3 定稿·2026.08.28·团队名称：VC (vibe coding)·参赛组别：开放赛题一（生成式大语言模型与智能体）

匿名要求：全文档不出现学校 / 学院 / 导师信息。

记录更改历史

序号	更改原因	版本	作者	更改日期	备注
1	初稿	0.1	VC	2026-08-21	从项目文档体系抽取
2	定稿（补技术对比/指标/团队）	0.2	VC	2026-08-27	补 3.1.1 技术对比、最终指标、团队信息
3	补覆盖质量门与模型辅助判定指标	0.3	VC	2026-08-28	2.2/3.1 新增 M4 能力项与最新验证数据

1 项目概况

1.1 背景和基础

文献调研是科研工作流中最基础也最耗时的环节：选题、开题、撰写 Related Work 需要在大量学术文献中完成检索、筛选、精读、归纳与引用。传统关键词搜索引擎难以理解"宽泛且细粒度"的研究问题；而直接使用通用大模型生成综述又存在两个核心问题：

黑盒不可信：生成过程不可见，引用可能是幻觉，无法向导师 / 评审证明"每句话都有出处"；

过程不可控：全自动担心跑偏，全手动又回到手工检索的耗时。

本项目以生成式大语言模型的语义理解与任务规划能力为基础，构建一个**可观测、可追踪、可控制的学术调研智能体工作台（研镜）**。用户输入一个研究问题，系统自动完成：问题澄清与计划生成 → 人工审批 → 多源学术检索 → 标题/摘要筛选 → 综述写作 → 引用核验 → 模型评估与审查 → 结构化导出，全过程每一步的状态、思考、成本与产物均可查看与干预。

1.2 场景和价值

目标场景：研究生选题、开题报告、Related Work 撰写、系统综述初稿。**核心价值：**

- **快：**一次完整调研（检索 → 筛选 → 写作 → 核验）真实运行约 13-17 分钟、成本约 ¥0.3（deepseek-v4-flash, xhigh 思考），对标"一周手工文献调研初稿"；
- **可信：**综述中每个论断绑定论文卡片与摘要证据；Reviewer 对引用做多源交叉核验（Crossref DOI 字段级 + arXiv 批量），输出"可信 / 存疑 / 不可核验"分级；
- **可控：**计划与成品两个强制审批点，支持打回修改多轮迭代；宽泛问题先澄清锚点再检索；预算、失败源、降级补偿全部可见；
- **透明：**每个角色的系统提示词、思考过程、上下文、工具调用与人民币成本可观测，不是黑盒生成。

1.3 所需支持

- 计算与存储：本地运行即可（Node.js 22 + SQLite），浏览器访问；
- 模型：OpenAI 兼容接口（DeepSeek / Qwen / OpenAI 均可），用户自带 key；
- 学术数据源：arXiv、Crossref、OpenAlex、Semantic Scholar 等公开学术 API（免费额度 + 可申请免费 key），Unpaywall 兜底获取开放全文。

2 项目规划

2.1 整体目标

输入一个研究问题，交付一份**可溯源、可审计的调研综述初稿**，并让全过程可观测、可干预、成本可控。产品目标：一杯咖啡时间完成一周文献调研初稿；每一步可查、每句引用可溯源、成本可控。

2.2 技术创新点

产物级多角色编排（区别于通用 Agent 嵌套）：planner / researcher / selector /

writer / evaluator / reviewer 六个角色通过工作流引擎状态机编排，角色间 **不共享上下文**，仅通过产物文件（artifact）交接——隔离上下文污染；人类只审"方案"和"成品"两个节点，中间的发现与修正不打扰用户；

引用级溯源与核验闭环：综述每个论断绑定证据卡片与摘要片段；Reviewer 用

Crossref / arXiv 多源交叉核验引用真实性，输出分级报告，从机制上对抗"AI 综述幻觉"；

全流程可观测的三支柱：思考、系统提示词、上下文、工具调用、人民币成本

实时可见；产物带版本历史，打回修改可对比；

模型无关 + 成本可控：任意 OpenAI 兼容模型可接入；单次调研 ≈¥0.3，

usage 全量落库，成本可审计；

检索层工程化：多源并发检索 + 源级健康降级补偿（预算型 429 快速失败、

失效源自动补偿）、图表标题等结构噪声过滤、引文雪球补候选；

覆盖质量门 + 模型辅助覆盖判定：计划子问题与证据池做覆盖矩阵

（覆盖/部分/缺失），缺口自动触发二次检索回环（≤3 轮）；在规则预筛之上引入 模型对全部子问题批量精判，可降级"词元撞车"造成的假阳性覆盖并精确归位支撑论文，使"哪些问题真的有文献支撑"成为可验证、可展示的能力。

3 实施方案

3.1 技术可行性分析

已完成 MVP 全闭环并多轮真实运行验证：

验证项	结果
端到端流程	七步完整 / 六步调研模板均真实跑通（澄清 → 审批 → 检索 → 筛选 → 写作/评估 → 核验 → 导出），单次 13 分钟级
检索广度	单次运行命中/去重 1259-3041，候选池 22-38，入选 15-21（高相关占比高）
覆盖质量门	覆盖矩阵（子问题→支撑论文→判定）+ 缺口自动二次检索回环；模型辅助精判使规则假阳性可被发现并降级（A/B 对比：同一证据池下规则全绿、模型抓出 2 处降级并精确归位支撑论文）
成本	≈¥0.3 / 13-14 分钟（含审批等待；deepseek-v4-flash，max 思考）
引用核验	逐条核验 + 分级报告，DOI/arXiv 多源交叉
可靠性	164+10(其余工作区合计28) 共 192 个单元测试全绿；审批乐观锁、WS 断线对账、源熔断/降级

与已有研究的定位对比：LitSearch（EMNLP 2024）证明"研究问题 → 特定论文"检索对BM25 / 密集检索仍有挑战；PaSa（ACL 2025）用双 Agent + RL 强化论文搜索；SPAR 用RefChain 查询分解。本项目不追求在纯检索基准上打榜，而是把检索作为工作流的一环，创新点在于**编排、治理与溯源**——检索只是证据来源，selector 分级、引文雪球、引用核验与结构化导出共同构成可交付价值。检索层已实现 RefChain 子问题分解、同义词扩展、时间过滤、引文雪球与源降级补偿，离线评测（LitSearch 30 条分层抽样）显示源健康修复后单查询耗时下降 62%、失败噪音清零；recall@20 的提升依赖 S2 key与向量检索升级（M3 方向）。

3.2 技术细节

- 编排层：WorkflowEngine 状态机（步骤、审批、产物版本、决策落库）；
角色运行时复用 pi-coding-agent SDK（等价于直接使用模型 SDK），禁用编码工具，系统提示词按角色注入，每角色独立会话隔离；
- 检索层：arXiv / Crossref / OpenAlex / Semantic Scholar 四源并发 + 去重合并 +
相关度加权排序；源级健康注册表（预算型 429 快速失败、冷却重探、失效补偿）；Crossref 图表标题噪声过滤；候选池 → selector 标题/摘要筛选 → 引文雪球补充 → gap 二次检索；
- 生成与审查层：Writer 按大纲撰写带引用标注综述（全文摘录前 3 篇控制上下文）；
evaluator 模型评估（主题命中/相关度/覆盖）；reviewer 引用多源核验；summarizer 输出主题分组 + 相关度分级 + 引用清单（Markdown / BibTeX）；
- 数据与可观测：SQLite（仓储抽象，后续可换 PostgreSQL）；usage_records 全量落库（token / 成本 / 缓存命中），cost-report 与评测脚本可复现指标。

3.3 计划和分工

阶段	时间	内容
M1 骨架	8/12-8/14	workflow引擎、角色运行时接入、SQLite 仓储
M2 闭环	8/14-8/20	检索/筛选/写作/评估/审查/导出闭环 + 审批 UI + 评测成本闭环
M2.5 检索层加固	8/21	源降级补偿 + 图表噪声过滤（复测通过）
M3 打磨	8/22-8/26	UI 重设计（对话流布局）、精排/六维评分/导出、M3 三件套
M4 覆盖质量门	8/27-8/28	覆盖矩阵 + 缺口二次检索回环 + 模型辅助覆盖判定（真实验证）
材料与提交	8/28-9/1	竞赛材料定稿、演示视频、打包提交

分工：单人（VC），覆盖编排 / 检索 / 评估审查 / 材料与演示全流程。

4 参考资料

Ajith A, et al. LitSearch: A Retrieval Benchmark for Scientific Literature Search. EMNLP 2024. arXiv:2407.18940.

He Y, et al. PaSa: An LLM Agent for Comprehensive Academic Paper Search. ACL 2025. arXiv:2501.10120.

Shi X, et al. SPAR: Scholar Paper Retrieval with LLM-based Agents. arXiv:2507.15245.

Feldman S, et al. AstaBench: Rigorous Benchmarking of AI Agents. arXiv:2510.21652.

nature-skills (科研 Skill 流程规范, <https://github.com/Yuan1z0825/nature-skills>)

science-skills (Google DeepMind, <https://github.com/google-deepmind/science-skills>)

第八届中国研究生人工智能创新大赛初赛作品提交规范 / 项目文档模版