

竞赛项目文档初稿（附件 2 模板）

研镜：面向科研的透明学术调研智能体工作台

第八届中国研究生人工智能创新大赛·开放赛题一（生成式大语言模型与智能体） 版本：0.5 定稿·2026.09.01·团队名称：VC（vibe coding）·参赛组别：开放赛题一（生成式大语言模型与智能体） 匿名要求：全文档不出现学校/学院/导师信息。

记录更改历史

序号	更改原因	版本	作者	更改日期	备注
1	初稿	0.1	VC	2026-08-21	从项目文档体系抽取
2	定稿（补技术对比/指标/团队）	0.2	VC	2026-08-27	补 3.1.1 技术对比、最终指标、团队信息
3	补覆盖质量门与模型辅助判定指标	0.3	VC	2026-08-28	2.2/3.1 新增 M4 能力项与最新验证数据
4	角色数勘误（七角色）、测试数更新、补运行总览与引擎级取消	0.4	VC	2026-08-31	2.2/3.1/3.2 与最新实现对齐
5	补网页搜索补位（Firecrawl）与测试数更新	0.5	VC	2026-09-01	2.2 创新点 7、3.2 检索/生成层、3.1 可靠性 239 测试

1 项目概况

1.1 背景和基础

文献调研是科研工作流中最基础也最耗时的环节：选题、开题、撰写 Related Work 需要在大量学术文献中完成检索、筛选、精读、归纳与引用。传统关键词搜索引擎难以理解“宽泛且细粒度”的研究问题；而直接使用通用大模型生成综述又存在两个核心问题：

1. **黑盒不可信**：生成过程不可见，引用可能是幻觉，无法向导师 / 评审证明“每句话都有出处”；
2. **过程不可控**：全自动担心跑偏，全手动又回到手工检索的耗时。

本项目以生成式大语言模型的语义理解与任务规划能力为基础，构建一个 **可观测、可追踪、可控制的学术调研智能体工作台**（研镜）。用户输入一个研究问题，系统自动完成：问题澄清与计划生成 → 人工审批 → 多源学术检索 → 标题/摘要筛选 → 综述写作 → 引用核验 → 模型评估与审查 → 结构化导出，全过程每一步的状态、思考、成本与产物均可查看与干预。

1.2 场景和价值

目标场景：研究生选题、开题报告、Related Work 撰写、系统综述初稿。

核心价值：

- **快**：一次完整调研（检索 → 筛选 → 写作 → 核验）真实运行约 13-20 分钟、成本约 ¥0.3-1.0（视问题规模与检索回环轮数；usage 全量落库可审计），对标“一周手工文献调研初稿”；
- **可信**：综述中每个论断绑定论文卡片与摘要证据；Reviewer 对引用做多源交叉核验（Crossref DOI 字段级 + arXiv 批量），输出“可信 / 存疑 / 不可核验”分级；
- **可控**：计划与成品两个强制审批点，支持打回修改多轮迭代；宽泛问题先澄清锚点再检索；预算、失败源、降级补偿全部可见；
- **透明**：每个角色的系统提示词、思考过程、上下文、工具调用与人民币成本可观测，不是黑盒生成。

1.3 所需支持

- **计算与存储**：本地运行即可（Node.js 22 + SQLite），浏览器访问；
- **模型**：OpenAI 兼容接口（DeepSeek / Qwen / OpenAI 均可），用户自带 key；
- **学术数据源**：arXiv、Crossref、OpenAlex、Semantic Scholar 等公开学术 API（免费额度 + 可申请免费 key），Unpaywall 兜底获取开放全文。

2 项目规划

2.1 整体目标

输入一个研究问题，交付一份**可溯源、可审计的调研综述初稿**，并让全过程可观测、可干预、成本可控。产品目标：一杯咖啡时间完成一周文献调研初稿；每一步可查、每句引用可溯源、成本可控。

2.2 技术创新点

1. **产物级多角色编排（区别于通用 Agent 嵌套）**：planner / researcher / selector / writer / evaluator / reviewer / summarizer 七个角色通过工作流引擎状态机编排，角色间 **不共享上下文**，仅通过产物文件（artifact）交接——隔离上下文污染；人类只审“方案”和“成品”两个节点，中间发现与修正不打扰用户；
2. **引用级溯源与核验闭环**：综述每个论断绑定证据卡片与摘要片段；Reviewer 用 Crossref / arXiv 多源交叉核验引用真实性，输出分级报告，从机制上对抗“AI 综述幻觉”；
3. **全流程可观测的三支柱**：思考、系统提示词、上下文、工具调用、人民币成本实时可见；运行总览卡以状态机与按角色成本条形图呈现全局进度与开销；产物带版本历史，打回修改可对比；运行中可随时引擎级取消（停止按钮）；
4. **模型无关 + 成本可控**：任意 OpenAI 兼容模型可接入；单次调研 $\approx$ ¥0.3，usage 全量落库，成本可审计；
5. **检索层工程化**：多源并发检索 + 源级健康降级补偿（预算型 429 快速失败、失效源自动补偿）、图表标题等结构噪声过滤、引文雪球补候选；
6. **覆盖质量门 + 模型辅助覆盖判定**：计划子问题与证据池做覆盖矩阵（覆盖/部分/缺失），缺口自动触发二次检索回环（ ≤ 3 轮）；在规则预筛之上引入模型对全部子问题批量精判，可降级“词元撞车”造成的假阳性覆盖并精确归位支撑论文，使“哪些问题真的有文献支撑”成为可验证、可展示的能力；
7. **网页搜索补位（工程实践类缺口）**：对学术文献天然稀疏的工程实践类子问题（如框架记忆机制、Agent 编排实践），以官方文档白名单为确定性优先种子，白名单未命中时经 Firecrawl 真实网页搜索兜底（search + scrape，预算纪律控制免费额度），命中权威网页作为 writer 补充参考，扩展“可验证”到工程实践证据。

3 实施方案

3.1 技术可行性分析

已完成 MVP 全闭环并多轮真实运行验证：

验证项	结果
端到端流程	七步完整 / 六步调研模板均真实跑通（澄清→审批→检索→筛选→写作/评估→核验→导出），单次 13-20 分钟
检索广度	8/31 实测：命中/去重 799/542，候选 40，引文雪球+缺口补检新增 15，入选 44（高相关 23）；历史区间命中 1259-3041
覆盖质量门	覆盖矩阵（子问题→支撑论文→判定）+ 缺口自动二次检索回环（8/31 实测 4 条缺口查询全部补检）；模型辅助精判使规则假阳性可被发现并降级（A/B 对比：同一证据池下规则全绿、模型抓出 2 处降级并精确归位支撑论文）
成本	¥0.3-1.0 / 13-20 分钟（含审批等待；deepseek-v4-flash；8/31 实测 ¥0.96：29 万输入 / 10 万输出 token）
引用核验	逐条核验 + 分级报告，DOI/arXiv 多源交叉；8/31 实测草稿 177 处引用 / 去重 44 条，越界缺失 0
六维评估	8/31 实测综合 5.2/5（主题匹配 5·相关度 4·大纲覆盖 5·引用可信 5·完整性 5·来源失败 2）
可靠性	239 个单元测试全绿（48 文件，web/server/data/shared 四包）；审批乐观锁、WS 断线对账、源熔断/降级、引擎级取消

与已有研究的定位对比：LitSearch（EMNLP 2024）证明“研究问题→特定论文”检索对 BM25 / 密集检索仍有挑战；PaSa（ACL 2025）用双 Agent + RL 强化论文搜索；SPAR 用 RefChain 查询分解。本项目不追求在纯检索基准上打榜，而是把检索作为 workflow 的一环，创新点在于**编排、治理与溯源**——检索只是证据来源，selector 分级、引文雪球、引用核验与结构化导出共同构成可交付价值。检索层已实现 RefChain 子问题分解、同义词扩展、时间过滤、引文雪球与源降级补偿，离线评

测（LitSearch 30 条分层抽样）显示源健康修复后单查询耗时下降 62%、失败噪音清零；recall@20 的提升依赖 S2 key 与向量检索升级（M3 方向）。

3.2 技术细节

- **编排层**：WorkflowEngine 状态机（步骤、审批、产物版本、决策落库）；角色运行时复用 pi-coding-agent SDK（等价于直接使用模型 SDK），禁用编码工具，系统提示词按角色注入，每角色独立会话隔离；
- **检索层**：arXiv / Crossref / OpenAlex / Semantic Scholar 四源并发 + 去重合并 + 相关度加权排序；源级健康注册表（预算型 429 快速失败、冷却重探、失效补偿）；Crossref 图表标题噪声过滤；候选池 → selector 标题/摘要筛选 → 引文雪球补充 → gap 二次检索；工程实践类缺口以官方文档白名单为种子 + Firecrawl 网页搜索兜底（search/scrape，预算化：每子问题至多 1 次 search、摘要 ≤2000 字符）；
- **生成与审查层**：Writer 按大纲撰写带引用标注综述（全文摘录前 3 篇控制上下文；工程实践段可引用“补充参考（官方文档 / 网页）”）；evaluator 模型评估（主题命中 / 相关度 / 覆盖）；reviewer 引用多源核验；summarizer 输出主题分组 + 相关度分级 + 引用清单（Markdown / BibTeX）；
- **数据与可观测**：SQLite（仓储抽象，后续可换 PostgreSQL）；usage_records 全量落库（token / 成本 / 缓存命中），cost-report 与评测脚本可复现指标。

3.3 计划和分工

阶段	时间	内容
M1 骨架	8/12-8/14	工作流引擎、角色运行时接入、SQLite 仓储
M2 闭环	8/14-8/20	检索/筛选/写作/评估/审查 / 导出闭环 + 审批 UI + 评测成本闭环
M2.5 检索层加固	8/21	源降级补偿 + 图表噪声过滤（复测通过）
M3 打磨	8/22-8/26	UI 重设计（对话流布局）、精排/六维评分/导出、M3 三件套
M4 覆盖质量门	8/27-8/28	覆盖矩阵 + 缺口二次检索回环 + 模型辅助覆盖判定（真实验证）
材料与提交	8/28-9/1	竞赛材料定稿、演示视

阶段	时间	内容
		频、打包提交

分工：单人（VC），覆盖编排 / 检索 / 评估审查 / 材料与演示全流程。

4 参考资料

1. Ajith A, et al. LitSearch: A Retrieval Benchmark for Scientific Literature Search. EMNLP 2024. arXiv:2407.18940.
2. He Y, et al. PaSa: An LLM Agent for Comprehensive Academic Paper Search. ACL 2025. arXiv:2501.10120.
3. Shi X, et al. SPAR: Scholar Paper Retrieval with LLM-based Agents. arXiv:2507.15245.
4. Feldman S, et al. AstaBench: Rigorous Benchmarking of AI Agents. arXiv:2510.21652.
5. nature-skills（科研 Skill 流程规范，<https://github.com/Yuan1z0825/nature-skills>）
6. science-skills（Google DeepMind，<https://github.com/google-deepmind/science-skills>）
7. 第八届中国研究生人工智能创新大赛初赛作品提交规范 / 项目文档模版